## Organizačné poznámky

- DÚ1 je zverejnená, odovzdávanie do stredy 11.11. 22:00
- Journal club: Rozdelenie do skupín / inštrukcie na konci prednášky
- Najbližší journal club termín 20.11.

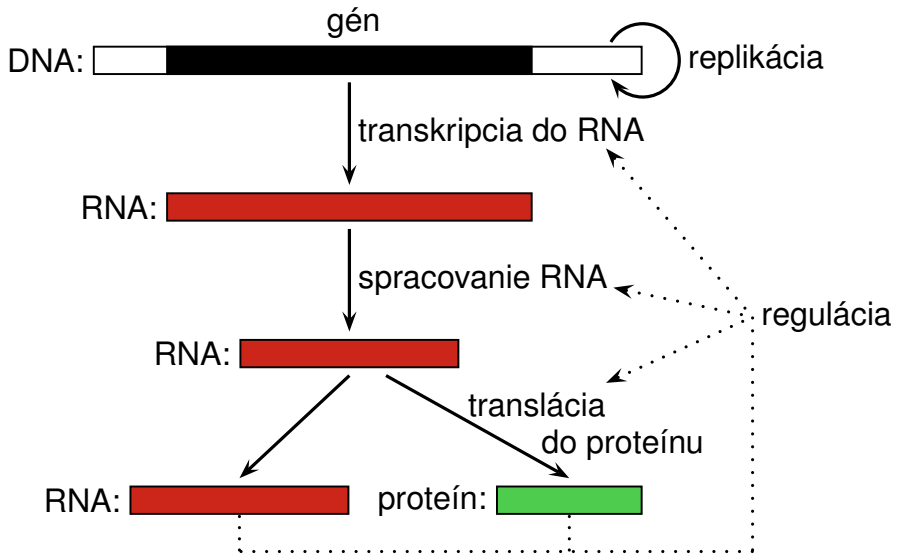
# Hľadanie génov

**Askar Gafurov**

**22.10.2026**



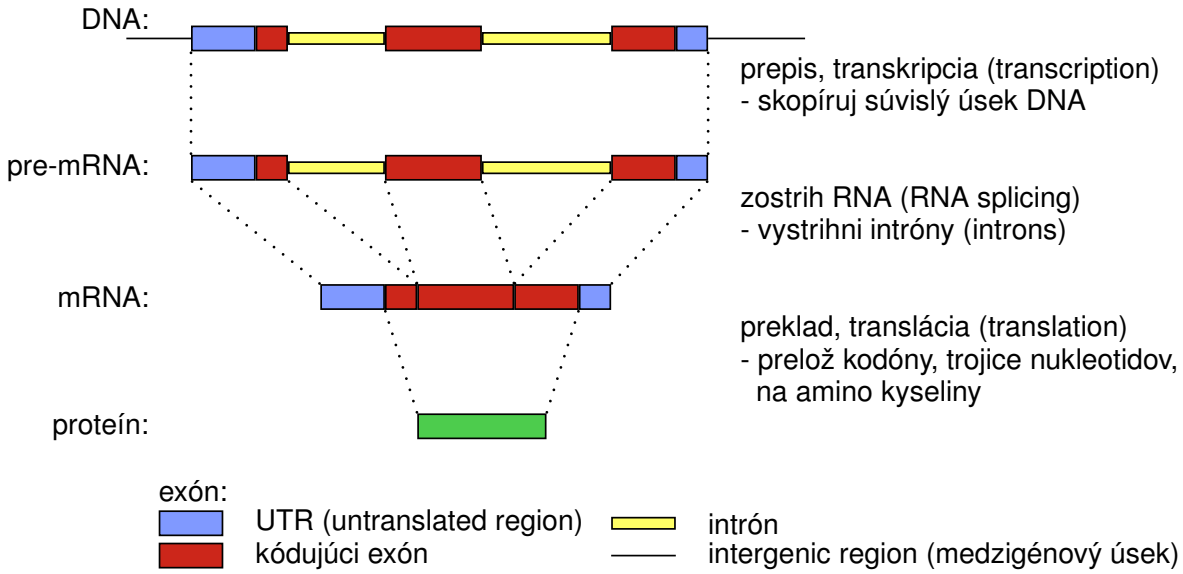
## Čo s osekvenovanými genómami?



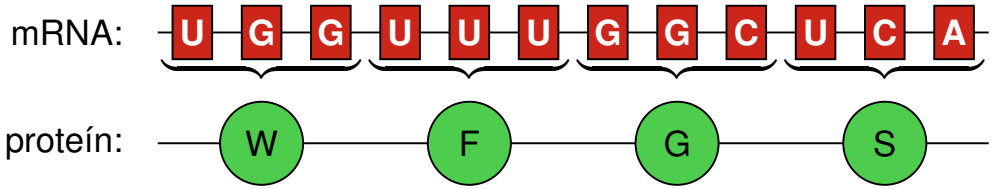

- gény kódujúce proteíny (dnešná prednáška)
- RNA gény
- signály pre reguláciu transkripcie, zostrihu, atď
- pseudogény (nefunkčné kópie génov)
- repetitívne sekvencie, opakovania (sequence repeats)

# Štruktúra eukaryotických génov

## Proces syntézy proteínov:




**Translácia:** tri bázy mRNA (kodón) $\rightarrow$ aminokyselina proteínu



## Ľudský genóm

### Gény kódujúce proteíny

– cca 20 000, pokrývajú 40% genómu

– cca 10 exónov v géne

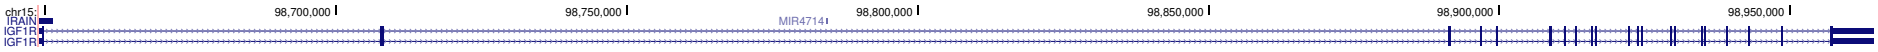
– exóny pokrývajú 2% genómu

– kódujúce exóny 1.2% genómu

### Repetitívne sekvencie

– pokrývajú 49% genómu

**Príklad:** gén IGF1R zaberá 315 569nt, z toho kóduje 4101nt v 21 exónoch



## Bioinformatický problém: hľadanie génov

**Cieľ:** nájsť všetky gény kódujúce proteíny v genóme.

Tým získame katalóg všetkých proteínov.

### Zjednodušenia:

- neuvažujeme alternatívny zostrih, prekrývajúce sa gény
- nehľadáme neprekladané oblasti (UTRs) na začiatku a konci génu

## Bioinformatický problém: hľadanie génov

**Vstup:** sekvencia DNA

```
cggtgaaactgcacgattgttgctggcttaaagatagaccaatcagagtgtgtaacgtca
tatttagcgtcttctatcatccaatcactgcactttacacactataaatagagcagctca
tgggcgtatttgcgctagtgttgggtgttccgctgtgctgttttccgtcatggctcgca
ctaagcaaactgctcggaagtctactggtggcaaggcgccacgcaaacagttggccacta
aggcagcccgcaaaagcgctccggccaccggcggcgtgaaaaagccccaccgctaccggc
cgggcaccgtggctctgcgcgagatccgccgttatcagaagtccactgaactgcttattc
gtaaactacctttccagcgcctggtgcgcgagattgcgcaggactttaaaacagacctgc
gtttccagagctccgctgtgatggctctgcaggaggcgtgcgaggcctacttggtagggc
tatttgaggacactaacctgtgcgccatccacgccaagcgcgtcactatcatgcccaagg
acatccagctcgcccgccgcatccgcggagagagggcgtgattactgtggtctctctgac
```

## Bioinformatický problém: Hľadanie génov

**Cieľ:** označ každú bázu ako intrón/exón/medzigénovú oblasť

cggtgaaactgcacgattgttgctggcttaaagatagaccaatcagagtgtgtaacgtca

tatttagcgtcttctatcatccaatcactgcactttacacactataaatagagcagctca

tgggcgtatttgcgctagtgttgggtgttccgctgtgctgtttttccgtcatggctcgca

ctaagcaaactgctcggaagtctactggtggcaaggcgccacgcaaacagttggccacta

aggcagcccgcaaaagcgctccggccaccggcggcgtgaaaaagccccaccgctaccggc

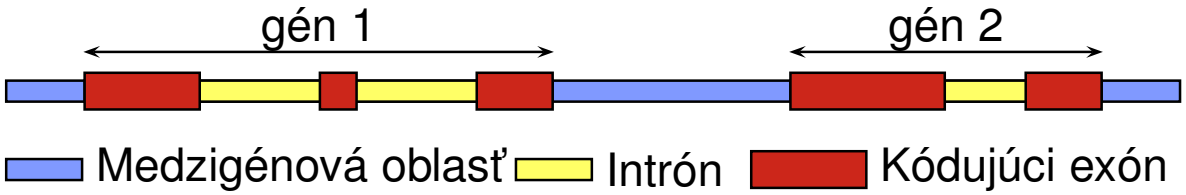
cgggcaccgtggctctgcgcgagatccgccgttatcagaagtccactgaactgcttattc

gtaaactacctttccagcgcctggtgcgcgagattgcgcaggactttaaaacagacctgc

gtttccagagctccgctgtgatggctctgcaggaggcgtgcgaggcctacttggtagggc

tatttgaggacactaacctgtgcgccatccacgccaagcgcgtcactatcatgcccaagg

acatccagctcgcccgccgcatccgcggagagagggcgtgattactgtggtctctctgac



## Bioinformatický problém: hľadanie génov

**Vstup:** sekvencia DNA

**Cieľ:** označ každú bázu ako intrón/exón/medzigénovú oblasť (anotácia)

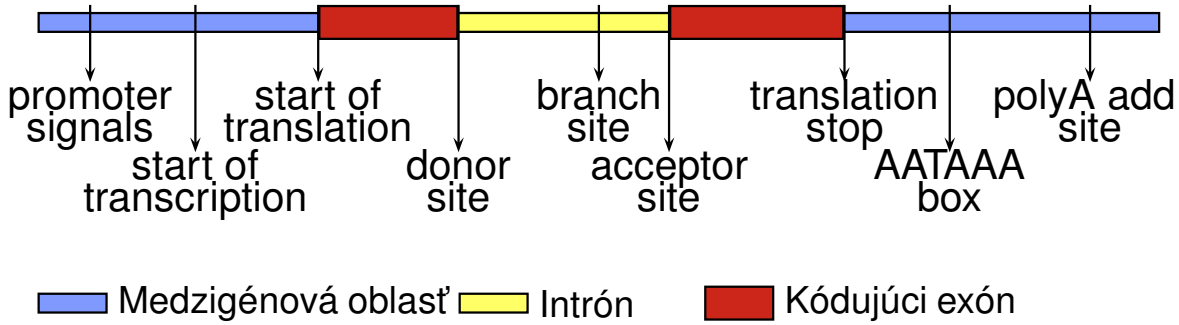
- Toto nie je dobre definovaný problém!

  Ako spoznáme, čo je gén?

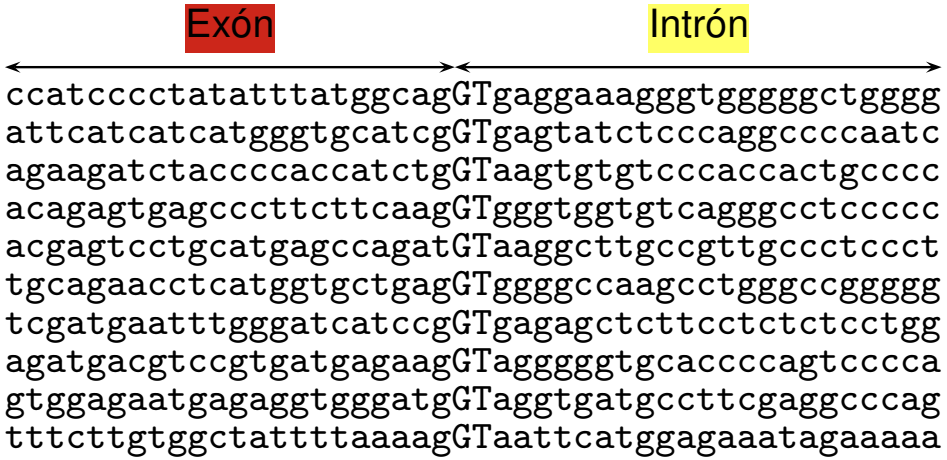
## Ako spoznáme gény?

**Signály** na hraniciach exónov:

krátke reťazce, kde sa viažu komplexy zúčastnujúce sa na expresii génu




**Príklad signálu:** miesto zostrihu



## Ako spoznáme gény?

### Zloženie sekvencie:

- iná frekvencia $k$-tic báz v kódujúcich a nekódujúcich oblastiach,
- kódujúce oblasti sú 3-periodické,
- stop kodóny (TAA, TGA, TAG) len na konci posledného kódujúceho exónu.

**Príklad:** ak uvažujeme len jednotlivé bázy, exóny majú viac C a G (ľudský genóm)

| | a | c | g | t |
|---|---|---|---|---|
| kódujúci exón 0 | 0.26 | 0.26 | 0.32 | 0.16 |
| 1 | 0.30 | 0.24 | 0.20 | 0.26 |
| 2 | 0.17 | 0.32 | 0.31 | 0.20 |
| intrón | 0.26 | 0.22 | 0.22 | 0.30 |
| medzig. | 0.27 | 0.23 | 0.23 | 0.27 |

## Bioinformatický problém: hľadanie génov

**Vstup:** sekvencia DNA

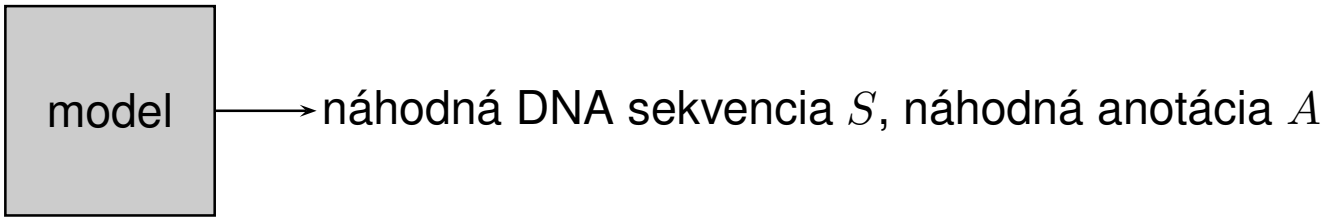
**Cieľ:** označ každú bázu ako intrón/exón/medzigénovú oblasť (anotácia)

- Toto nie je dobre definovaný problém!
  Ako spoznáme, čo je gén?
- Žiadna informácia nám neumožňuje jednoznačne určiť, čo je gén.
- Chceme **skórovací systém**, ktorý povie, ako dobre potenciálna anotácia zodpovedá našim znalostiam.
- Potom hľadáme anotáciu (alebo: segmentáciu pôvodnej sekvencie na neprekrývajúce sa regióny, ktoré reprezentujú intróny, exóny a medzigénové úseky) **s maximálnym skóre.**
- Na definíciu skórovacieho systému použijeme **pravdepodobnostné modely.**

## Pravdepodobnostný model génov

Žiadna informácia nám neumožňuje jednoznačne určiť, čo je gén.

Skombinujeme dostupnú informáciu pravdepodobnostným modelom.



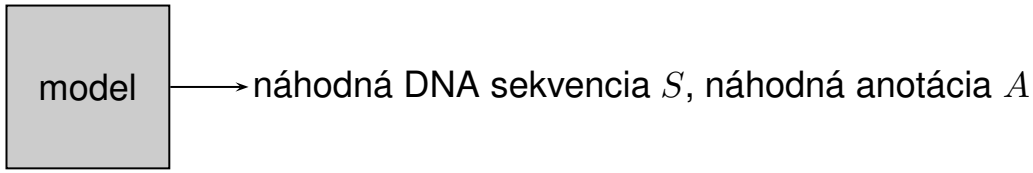

$\Pr(S, A)$ – pravdepodobnosť, že model vygeneruje pár $(S, A)$.

Model zostavíme tak, aby páry s vlastnosťami podobnými skutočným génom mali veľkú pravdepodobnosť.

**Použitie:** pre novú sekvenciu $S$ nájdi najpravdepodobnejšiu anotáciu

$A = \arg\max_A \Pr(A|S)$

## Pravdepodobnostný model génov




**Použitie:** pre sekvenciu $S$ nájdi najpravdepodobnejšiu anotáciu $A$

**Hračkársky príklad modelu:** sekvencie dĺžky 2

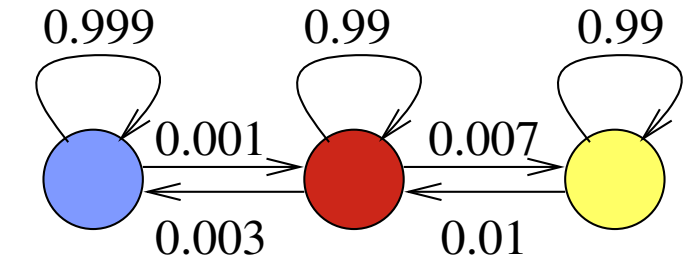
Tabuľka pravdepodobností pre 16 sekvencií, 9 anotácií (súčet 1)

Najpravdepodobnejšia anotácia pre $S =$aa je aa.

| | | | | | | |
|---|---|---|---|---|---|---|
| aa | 0.008 | ac | 0.009 | ag | 0.0085 | ... |
| aa | 0 | ac | 0 | ... | | |
| aa | 0.011 | ... | | | | |
| aa | 0 | | | | | |
| aa | 0.009 | | | | | |
| aa | 0 | | | | | |
| aa | 0.007 | | | | | |
| aa | 0 | | | | | |
| aa | 0.010 | | | | | |

## Skrytý Markovov model, hidden Markov model (HMM)

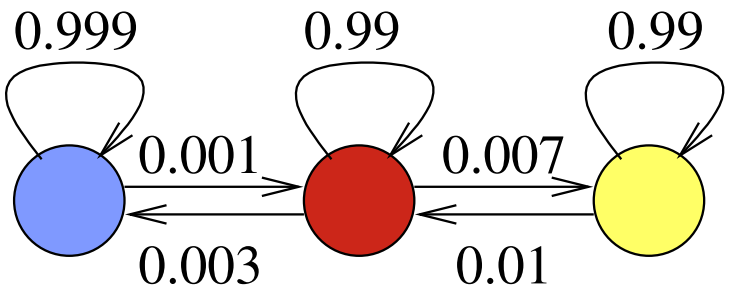
Spôsob, ako zadefinovať model pre dlhšie sekvencie.




| | | |
|---|---|---|
| a:0.27 | a:0.24 | a:0.26 |
| c:0.23 | c:0.27 | c:0.22 |
| g:0.23 | g:0.28 | g:0.22 |
| t:0.27 | t:0.21 | t:0.30 |

- Konečný automat, stavy napr. exón, intrón, medzigénová oblasť
- Sekvenciu aj anotáciu generuje bázu po báze
- V každom kroku je v jednom stave a náhodne vygeneruje jednu bázu podľa tabuľky v stave
- Potom sa presunie do ďalšieho stavu podľa pravdepodobností na hranách

## Skrytý Markovov model (HMM)




| | | |
|---|---|---|
| a:0.27 | a:0.24 | a:0.26 |
| c:0.23 | c:0.27 | c:0.22 |
| g:0.23 | g:0.28 | g:0.22 |
| t:0.27 | t:0.21 | t:0.30 |

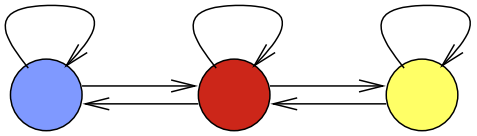
Predpokladajme, že model vždy začína v modrom stave.

**Príklad:**

$$\Pr(\text{aca}) = 0.27 \cdot 0.001 \cdot 0.27 \cdot 0.99 \cdot 0.24 = 0.000017$$

$$\Pr(\text{aca}) = 0.27 \cdot 0.999 \cdot 0.23 \cdot 0.999 \cdot 0.27 = 0.017$$

## Matematické označenie



Sekvencia $S_1, \ldots, S_n$

Anotácia $A_1, \ldots, A_n$

## Parametre modelu:

Prechodová pravdepodobnosť $a(u, v) = \Pr(A_{i+1} = v | A_i = u)$,

Emisná pravdepodobnosť $e(u, x) = \Pr(S_i = x | A_i = u)$,

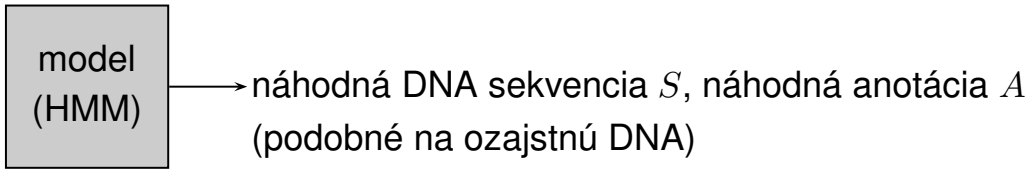
Počiatočná pravdepodobnosť $\pi(u) = \Pr(A_1 = u)$.

| $a$ | | | |
|---|---|---|---|
| | 0.99 | 0.007 | 0.003 |
| | 0.01 | 0.99 | 0 |
| | 0.001 | 0 | 0.999 |

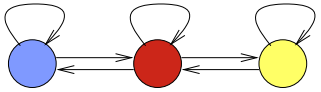
| $e$ | a | c | g | t |
|---|---|---|---|---|
| | 0.24 | 0.27 | 0.28 | 0.21 |
| | 0.26 | 0.22 | 0.22 | 0.30 |
| | 0.27 | 0.23 | 0.23 | 0.27 |

**Výsledná pravdepodobnosť:** $\Pr(A_1, \ldots, A_n, S_1, \ldots, S_n) =$
$\pi(A_1)e(A_1, S_1) \prod_{i=2}^{n} a(A_{i-1}, A_i)e(A_i, S_i)$

## Hľadanie génov s HMM

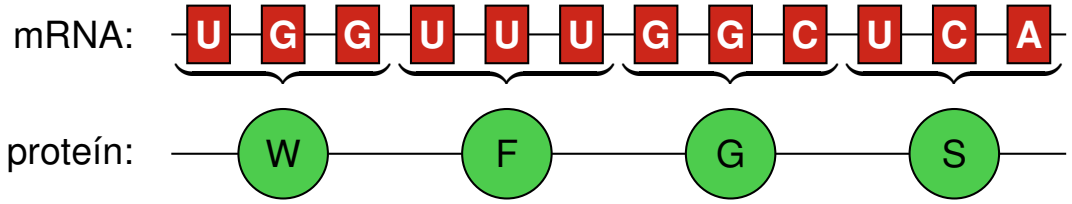



$\Pr(S, A)$ – pravdepodobnosť, že model vygeneruje pár $(S, A)$.

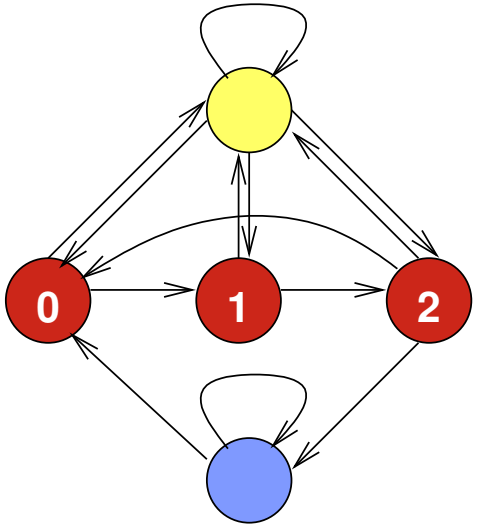
- **Určenie stavov a prechodov v modeli:** ručne, na základe poznatkov o štruktúre génu. 
- **Trénovanie parametrov:** emisné a prechodové pravdepodobnosti určíme na základe sekvencií so známymi génmi (**trénovacia množina**).
- **Použitie:** pre novú sekvenciu $S$ nájdi najpravdepodobnejšiu anotáciu $A = \arg\max_A \Pr(A|S)$
  Viterbiho algoritmus v čase $O(nm^2)$ (dynamické programovanie)

## HMM na hľadanie génov: 3-periodické exóny

Kodón (trojica báz) $\rightarrow$ jedna aminokyselina



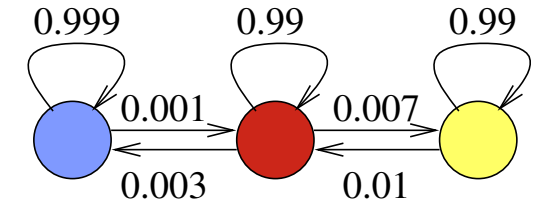

Namiesto jedného stavu pre exón použijeme tri stavy v cykle.

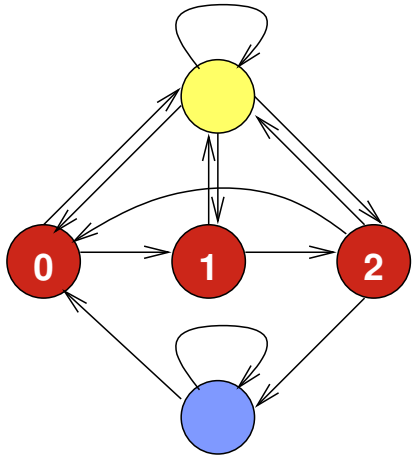



| $a$ | 0 | 1 | 2 | | |
|---|---|---|---|---|---|
| 0 | 0 | | 0 | | 0 |
| 1 | 0 | 0 | | | 0 |
| 2 | | 0 | 0 | | |
| | | | | | 0 |
| | | 0 | 0 | 0 | |

$\Pr(A_i|A_{i-1})$

## Nové stavy majú odlišné emisné pravdepodobnosti



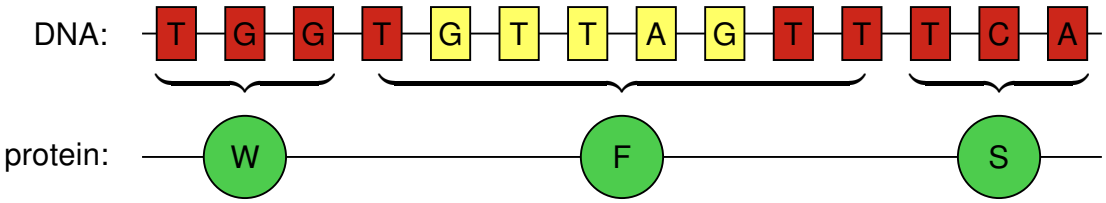



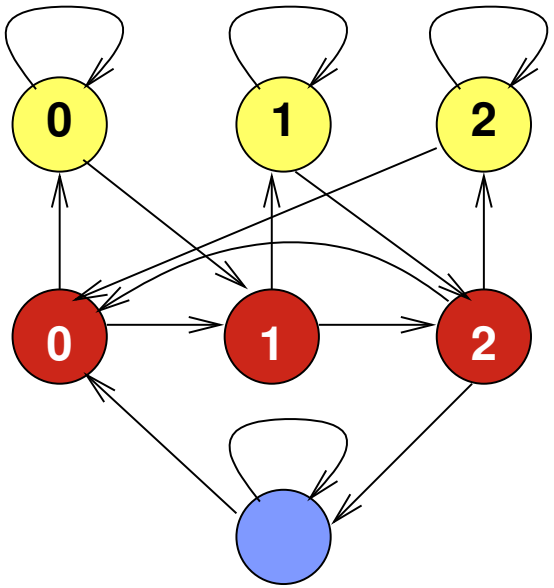

| $e$ | a | c | g | t |
|---|---|---|---|---|
| ■ | 0.24 | 0.27 | 0.28 | 0.21 |
| ■ | 0.26 | 0.22 | 0.22 | 0.30 |
| ■ | 0.27 | 0.23 | 0.23 | 0.27 |

| $e$ | a | c | g | t |
|---|---|---|---|---|
| 0 | 0.26 | 0.26 | 0.32 | 0.16 |
| 1 | 0.30 | 0.24 | 0.20 | 0.26 |
| 2 | 0.17 | 0.32 | 0.31 | 0.20 |
| ■ | 0.26 | 0.22 | 0.22 | 0.30 |
| ■ | 0.27 | 0.23 | 0.23 | 0.27 |

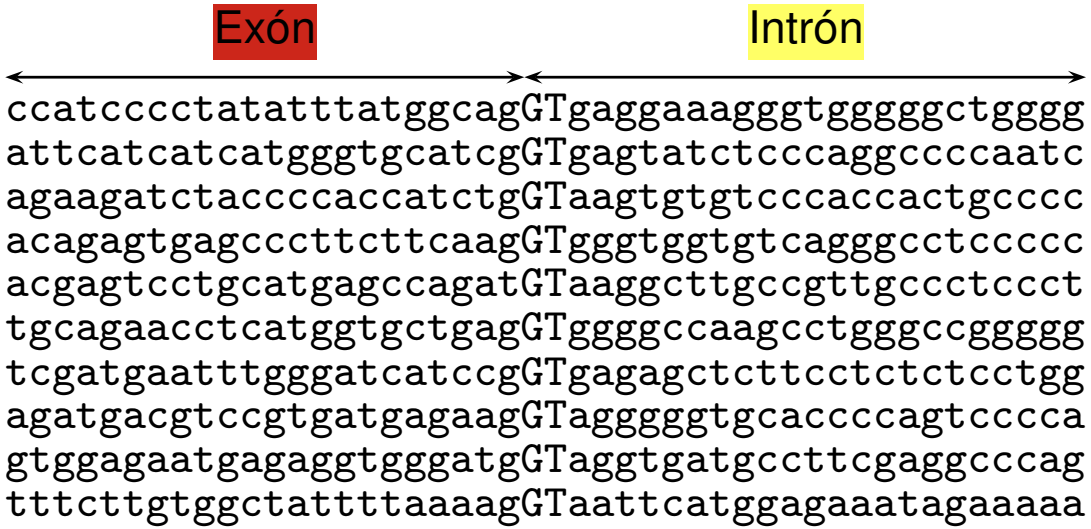
## HMM na hľadanie génov: konzistentné kodóny

Intrón môže prerušiť kodón uprostred, chceme pokračovať, kde sme prestali.

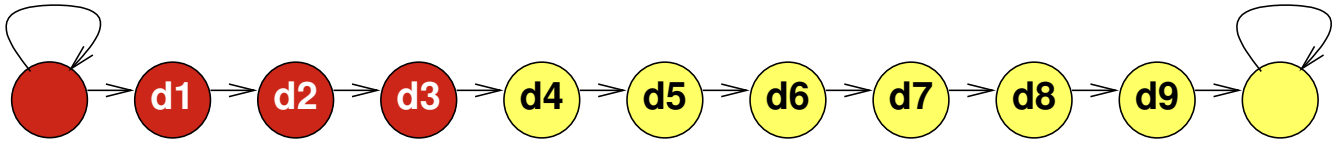


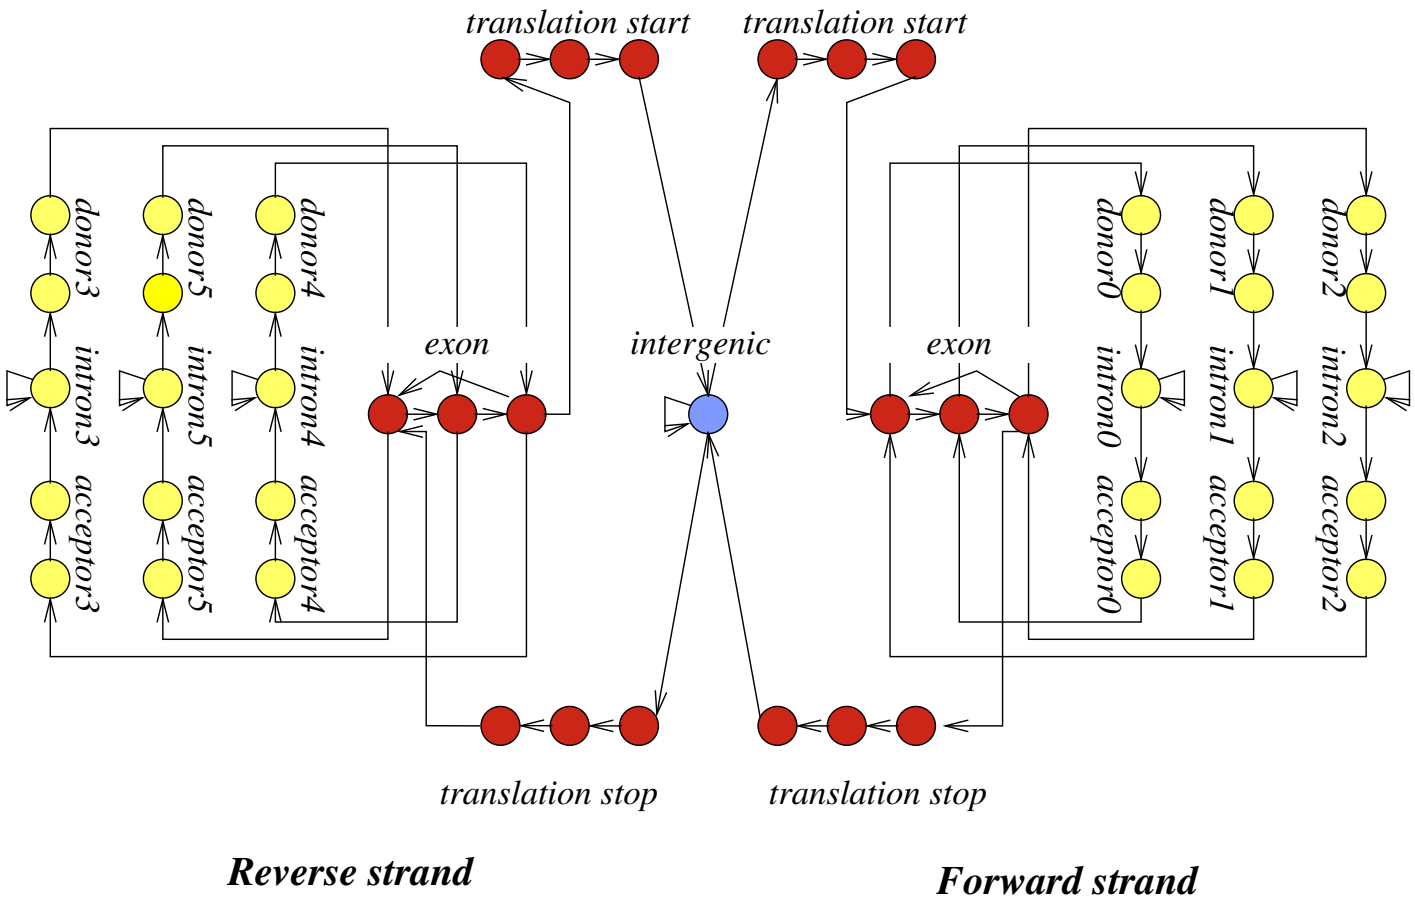
## HMM na hľadanie génov: signály




Pridaj sériu stavov medzi exón a intrón:



# HMM na hľadanie génov: celkový model



## Stavy vyšších rádov

**Rád 0:** emisná tabuľka $e$ určuje $\Pr(S_i|A_i)$

**Rád 1:** $e$ určuje $\Pr(S_i|A_i, S_{i-1})$

| $A_i$ | $S_{i-1}$ | a | c | g | t |
|---|---|---|---|---|---|
| | a | 0.24 | 0.23 | 0.34 | 0.19 |
| | c | 0.30 | 0.31 | 0.13 | 0.26 |
|  | g | 0.27 | 0.28 | 0.28 | 0.17 |
| | t | 0.13 | 0.28 | 0.38 | 0.21 |
| | a | 0.30 | 0.18 | 0.27 | 0.25 |
| | c | 0.32 | 0.28 | 0.06 | 0.35 |
|  | g | 0.27 | 0.22 | 0.27 | 0.24 |
| | t | 0.20 | 0.21 | 0.26 | 0.33 |

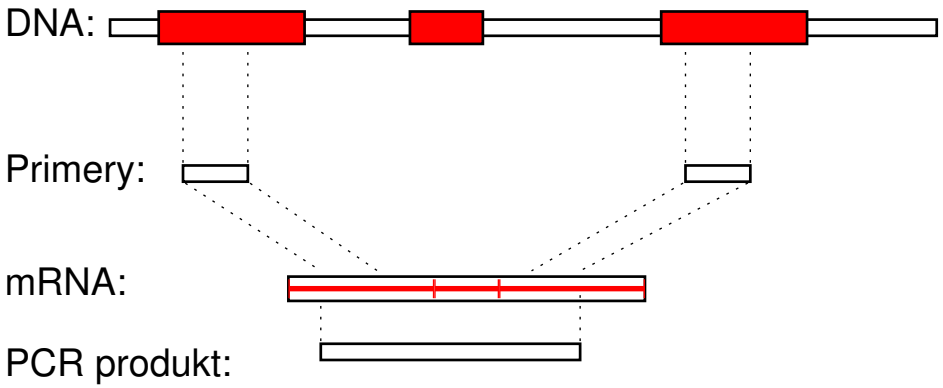
...

Na charakterizovanie exónov, intrónov atď používame rád 4-5.

## Experimentálne overovanie génov

### Overenie transkripcie a zostrihu

- **RNA-Seq:** sekvenovanie častí mRNA extrahovaných z bunky. Nie je cielené na konkrétny gén.
- **RT PCR:** cielene over konkrétny predpovedaný gén pomocou špecifických primerov.




**Problémy:** ťažko nájsť gény s expresiou iba za zvláštnych podmienok (napr. v embryu), kontaminácia genómovou DNA, nejednoznačné namapovanie na genóm.

## Experimentálne overovanie génov

### Overenie translácie, prítomnosti proteínu

- Hmotnostná spektrometria (mass spectrometry) dokáže detegovať prítomnosť proteínu izolovaného napr. z 2D gélu.
- Metódy založené na protilátkach (antibody), prípadne špecifické techniky podľa typu proteínu.

## Príklady programov na hľadanie génov

### Len na základe sekvencie DNA:

HMMGene [Krogh 1997] (autor je priekopníkom HMM v bioinf.),

Genscan [Burge a Karlin 1997] (po mnohé roky štandard),

GeneZilla [Majoros a kol. 2004], ExonHunter [Brejová a kol. 2005], Augustus [Stanke a Waack 2003] (novšie programy založené na zovšeobecnených HMM).

CONTRAST [Gross 2007], CONRAD [DeCaprio 2007] (programy založené na conditional random fields, obmena HMM)

### Prokaryotické genómy:

GeneMark [Lukashin a Borodovsky 1998], Glimmer [Delcher a kol. 1999] a ďalšie.

## Vybrané programy na hľadanie génov

**Porovnávaním viacerých sekvencií:**

Twinscan [Korf a kol. 2001]

(prvý úspešný gene finder s dvoma genómami),

Exoniphy [Siepel a Haussler 2004]

(viacero genómov, nehľadá celé gény),

N-SCAN [Gross a Brent 2006]

(rozšírenie Twinscanu na viacero genómov).

**Iná informácia:** (napr. RNA-seq, príbuzné proteíny a pod.)

ExonHunter [Brejová a kol. 2005], Augustus [Stanke a kol. 2006],

Jigsaw [Allen a Salzberg 2005], Fgenesh++ [Solovyev 2006].

Augustus patrí dodnes medzi často používané programy.

## Obmedzenia hľadačov génov

- Alternatívny zostrih (alternative splicing): jeden gén môže vyprodukovať viacero mRNA molekúl. Programy väčšinou hľadajú iba jednu.




- Pretínajúce sa gény, resp. gény v intrónoch.
- Netypické gény (neobvyklé signály, veľmi krátke alebo dlhé exóny alebo intróny atď.)
- Hľadanie UTR a začiatku/konca transkripcie.

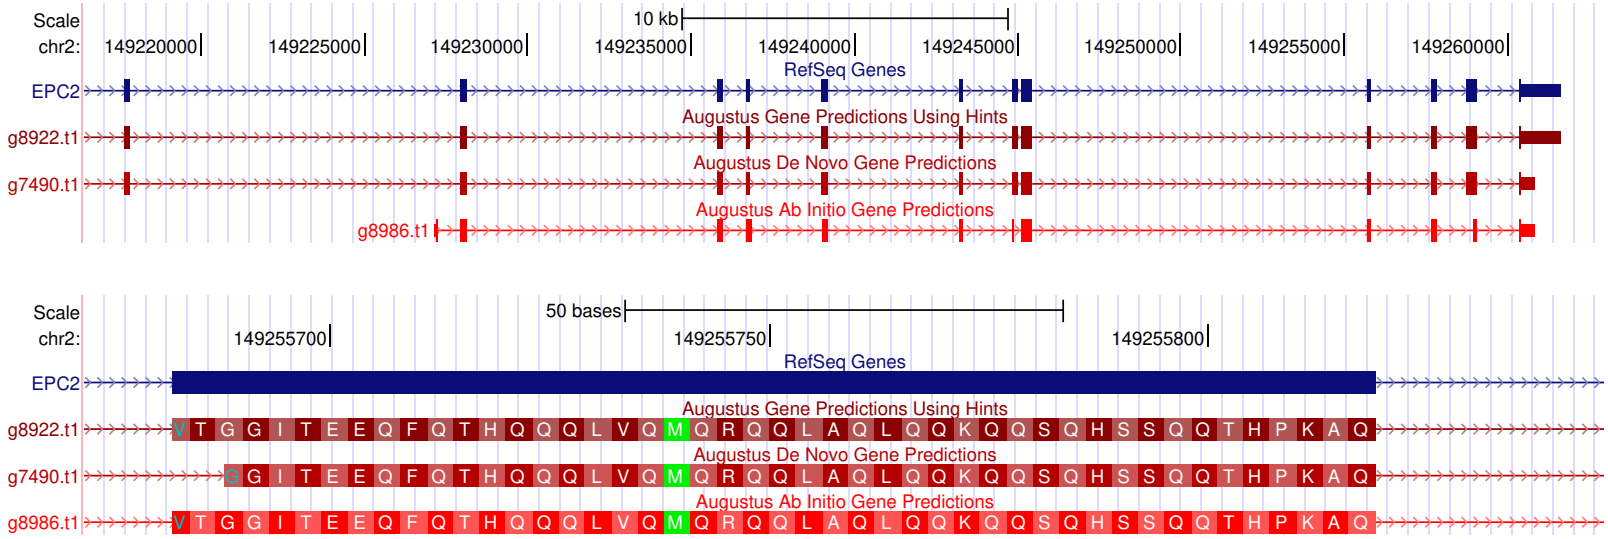
## Hľadače génov robia často chyby

Najlepšie metódy v 2005 na ľudskom genóme: [Guigo et al 2006]

20% génov, 60% exónov správne iba na základe DNA

35% génov, 65% exónov správne komparatívne

70% génov, 85% exónov správne s ďalšou informáciou



## Koľko génov má človek?

**Do 2001:** Rôzne odhady: **50 000–140 000** génov

**2001:** predbežná verzia ľudského genómu: **30 000–40 000** génov

**2004:** sekvencia ľudského genómu: **20 000–25 000** génov

**2007:** v katalógoch Ensembl, RefSeq a VEGA spolu **24 500** génov

[Clamp a kol. 2007] tvrdia, že iba **20 500** z nich je správnych

Ale sú gény, o ktorých ešte nevieme?

**2010:** RefSeq má **22 333** génov

Stále neistota $\pm 1000$ [Pertea, Salzberg 2010]

Rôzni ľudia sa môžu líšiť v desiatkach génov

**2012:** Projekt ENCODE odhaduje **20 687** génov kódujúcich proteíny,

v priemere 6 alternatívnych transkriptov na gén,

plus 8 800 krátkych a 9 600 dlhých RNA génov

## Zhrnutie

- Novo osekvenované genómy treba anotovať:
  určovať funkcie jednotlivým oblastiam sekvencie
- Príkladom anotácie je hľadanie génov kódujúcich proteíny
- Na hľadanie génov sa hodia skryté Markovove modely
- Modely robia veľa chýb, ale dajú nám základnú predstavu o polohe a počte génov, môžeme študovať ich funkciu

## Journal club: skupiny

- Zoznam skupín na stránke predmetu, každej skupine tiež príde spoločný email, aby ste sa vedeli navzájom nakontaktovať

## Journal club: prvé stretnutie - pred 20.11.

- Každý si najprv prečíta článok,
  potom sa koná stretnutie, kde o článku diskutujete, vysvetlíte si navzájom nejasnosti, plánujete písanie správy
- Dátum, čas a miesto oznámte aspoň 24 hodín vopred v diskusii na Moodli
- Po stretnutí napíšte krátku správu zo stretnutia do príslušnej položky v Moodli (kto sa zúčastnil, čo sa dohodlo, či sú nejaké problémy, stačí pár viet)
- Ak treba, dohodnite si s nami konzultácie